

**UNIVERSIDADE FEDERAL DA FRONTEIRA SUL
CAMPUS CHAPECÓ
CURSO DE CIÊNCIA DA COMPUTAÇÃO**

LEONARDO YURI DALLA CÔRTE BRANCALIONE

**DEFINIÇÃO DA MALHA AÉREA E AERONAVES PARA
UMA NOVA COMPANHIA AÉREA REGIONAL COM
HUB EM CHAPECÓ**

**CHAPECÓ
2025**

LEONARDO YURI DALLA CÔRTE BRANCALIONE

**DEFINIÇÃO DA MALHA AÉREA E AERONAVES PARA
UMA NOVA COMPANHIA AÉREA REGIONAL COM
HUB EM CHAPECÓ**

Trabalho de Conclusão de Curso apresentado ao Curso de Ciência da Computação da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciência da Computação.

Orientador: Prof. Dr. Andrei de Almeida Sampaio Braga

**CHAPECÓ
2025**

Brancaleone, Leonardo Yuri Dalla Côte

DEFINIÇÃO DA MALHA AÉREA E AERONAVES PARA
UMA NOVA COMPANHIA AÉREA REGIONAL COM *HUB* EM
CHAPECÓ / Leonardo Yuri Dalla Côte Brancaleone
- 2025.

56 f.

Orientador: Prof. Dr. Andrei de Almeida
Sampaio Braga

Trabalho de Conclusão de Curso (Graduação)
- Universidade Federal da Fronteira Sul, Curso
de Ciência da Computação, Chapecó, SC, 2025.

1. aviação regional 2. problema de aloca-
ção de frota 3. programação linear inteira I.
Braga, Dr. Andrei de Almeida Sampaio, ori-
ent. II. Universidade Federal da Fronteira Sul.
III. Título.

LEONARDO YURI DALLA CÔRTE BRANCALIONE

**DEFINIÇÃO DA MALHA AÉREA E AERONAVES PARA UMA NOVA COMPANHIA
AÉREA REGIONAL COM *HUB* EM CHAPECÓ**

Trabalho de Conclusão de Curso apresentado ao Curso de Ciência da Computação da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciência da Computação.

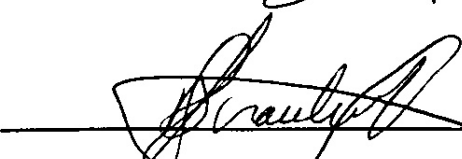
Orientador: Prof. Dr. Andrei de Almeida Sampaio Braga

Este Trabalho de Conclusão de Curso foi avaliado e aprovado pela banca avaliadora em: 04/07/2025.

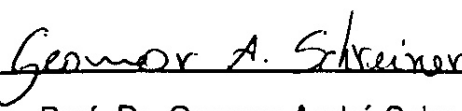
BANCA AVALIADORA



Prof. Dr. Andrei de Almeida Sampaio Braga - UFFS



Prof. Dr. Bráulio Adriano de Mello - UFFS



Prof. Dr. Geomar André Schreiner - UFFS

DEDICATÓRIA

Este trabalho é dedicado a todos aqueles que, direta ou indiretamente, acreditaram no meu potencial e me fizeram acreditar que era possível chegar até aqui.

“Quanto mais nos elevamos, menores parecemos aos olhos daqueles que não sabem voar.”

(Friedrich Nietzsche)

AGRADECIMENTOS

Agradeço primeiramente à minha mãe, Léia, e ao meu pai, Cláudio, pelo apoio constante e por estarem ao meu lado em todos os momentos da minha vida.

Aos meus avós, Olívia e Ari, por todos os ensinamentos que recebi, fundamentais para que eu me tornasse quem sou hoje.

À minha namorada, Jordana, minha sincera gratidão por todo o carinho, paciência e incentivo, e por acreditar sempre no meu potencial.

Aos meus amigos, pelo apoio e incentivo constantes em todos os momentos.

Ao meu professor e orientador, Andrei, pela paciência, dedicação e pelas valiosas orientações que foram essenciais para a realização deste trabalho.

Agradeço também ao Thiago de Jesus pela disponibilidade em compartilhar informações fundamentais para esta pesquisa.

Por fim, agradeço aos professores de curso, que sempre se dedicaram ao máximo para transmitir seus conhecimentos.

RESUMO

A aviação regional exerce um papel crucial na integração econômica e social de regiões afastadas dos grandes centros urbanos, dadas as dimensões territoriais do Brasil. Neste contexto, este trabalho buscou selecionar, adaptar e implementar um modelo matemático baseado em programação linear inteira para o problema de definição da malha aérea e seleção das aeronaves para uma nova companhia aérea regional com *hub* em Chapecó. O modelo escolhido, originalmente proposto por Jesus (2019) considerando um *hub* em Goiânia, foi aplicado com base em dados reais disponibilizados por órgãos oficiais através das plataformas DataSAS e Hórus, com foco nos anos de 2019 e 2024. O método incluiu informações sobre demanda, tarifas, infraestrutura aeroportuária e características das aeronaves. A implementação foi realizada com a linguagem de programação Python, com a utilização do resolvidor matemático Gurobi. Como uma adição ao modelo, foi incorporada uma nova restrição relacionada à superfície da pista, permitindo representar com maior fidelidade as condições operacionais da aviação regional brasileira. Os resultados revelaram a importância da diversificação da frota e apontaram a predominância de jatos regionais em ambos os anos analisados. Conclui-se que o modelo foi capaz de representar adequadamente o problema proposto, oferecendo apoio consistente para decisões estratégicas no planejamento da malha aérea e na seleção das aeronaves.

Palavras-Chave: aviação regional, problema de alocação de frota, programação linear inteira.

ABSTRACT

Regional aviation plays a crucial role in the economic and social integration of areas distant from major urban centers, given the territorial dimensions of Brazil. In this context, this study aimed to select, adapt, and implement a mathematical model based on integer linear programming to address the problem of defining the air network and selecting aircraft for a new regional airline with a hub in Chapecó. The chosen model, originally proposed by Jesus (2019) considering a hub in Goiânia, was applied using real-world data made available by official agencies through the DataSAS and Hórus platforms, focusing on the years 2019 and 2024. The method incorporated information on demand, fares, airport infrastructure, and aircraft characteristics. The implementation was carried out using the Python programming language and the Gurobi mathematical solver. As an addition to the model, a new constraint related to runway surface was added, allowing for a more accurate representation of the operational conditions of Brazilian regional aviation. The results revealed the importance of fleet diversification and indicated the predominance of regional jets in both years analyzed. It was concluded that the model was able to adequately represent the proposed problem, providing consistent support for strategic decisions in air network planning and aircraft selection.

Keywords: regional aviation, fleet allocation problem, integer linear programming.

LISTA DE FIGURAS

2.1	a) Rede <i>hub and spoke</i> pura. b) Rede <i>hub and spoke</i> híbrida – adaptado de uma figura de Choi, Lee e Park (2018).....	20
2.2	Uma malha aérea com um <i>hub</i> e oito <i>spokes</i> , adaptado de Azul (2024)	21
6.1	Exemplo resumido de planilha de alocações de aeronaves.....	39
6.2	Exemplo de implementação da atribuição da variável de decisão $BIN_{j,a}$	41
6.3	Exemplo de implementação da restrição de compatibilidade de superfície mínima da pista.....	41
6.4	Exemplo de implementação da função objetivo de maximização do lucro operacional	41
7.1	Malha aérea resultante para o ano de 2019.....	44
7.2	Malha aérea resultante para o ano de 2024.....	45

LISTA DE TABELAS

5.1	Aeronaves candidatas para o modelo	32
5.2	Classificação de superfícies	36
7.1	Especificações de <i>hardware</i> da máquina de simulação	43
7.2	Destinos selecionados para o ano de 2019	44
7.3	Destinos selecionados para o ano de 2024	44
7.4	Resultado da alocação com apenas um tipo de aeronave	46
7.5	Resultado da alocação com até dois tipos de aeronave	47
7.6	Resultado da alocação com até três tipos de aeronave	48
7.7	Resultado da alocação com até cinco tipos de aeronave	49
7.8	Resultado da alocação com até dez tipos de aeronave	50
7.9	Resultado da alocação sem limite de tipos de aeronave	51

LISTA DE SIGLAS

ANAC Agência Nacional de Aviação Civil

ASK Assento-quilômetro disponível (ASK, do inglês *Available Seat Kilometer*)

CASK Custo por assento-quilômetro (CASK, do inglês *Cost per Available Seat Kilometer*)

CSP Problema de escalonamento de tripulações (CSP, do inglês *Crew Scheduling Problem*)

DAC Departamento de Aviação Civil

FAP Problema de alocação de frota (FAP, do inglês *Fleet Assignment Problem*)

ICAO Organização da Aviação Civil Internacional (ICAO, do inglês *International Civil Aviation Organization*)

PLI Programação linear inteira

PO Pesquisa operacional

RPK Receita por passageiro-quilômetro (RPK, do inglês *Revenue Passenger Kilometers*)

TOR Receita operacional total (TOR, do inglês *Total Operating Revenue*)

TOC Custos operacionais totais (TOC, do inglês *Total Operating Costs*)

SUMÁRIO

1	INTRODUÇÃO	14
1.1	PROBLEMA	15
1.2	OBJETIVOS	15
1.2.1	OBJETIVO GERAL	15
1.2.2	OBJETIVOS ESPECÍFICOS	15
1.3	JUSTIFICATIVA	16
1.4	RESULTADOS OBTIDOS	16
2	FUNDAMENTAÇÃO TEÓRICA	18
2.1	MERCADO DA AVIAÇÃO REGIONAL	18
2.2	CONCEITOS DA AVIAÇÃO CIVIL	18
2.2.1	AGÊNCIA NACIONAL DE AVIAÇÃO CIVIL - ANAC	19
2.2.2	AERÓDROMO	19
2.2.3	<i>HUB AND SPOKE</i>	19
2.2.4	MALHA AÉREA	20
2.2.5	RECEITA OPERACIONAL TOTAL	21
2.2.6	RECEITA POR PASSAGEIRO-QUILÔMETRO	21
2.2.7	CUSTOS OPERACIONAIS TOTAIS	22
2.2.8	ASSENTO-QUILÔMETRO DISPONÍVEL	22
2.2.9	CUSTO POR ASSENTO-QUILÔMETRO	22
2.2.10	<i>YIELD</i>	22
2.3	PESQUISA OPERACIONAL	23
2.3.1	PROGRAMAÇÃO LINEAR INTEIRA	23
2.4	PROBLEMA DE ALOCAÇÃO DE FROTA	24
3	TRABALHOS RELACIONADOS	25
4	METODOLOGIA	28
5	MÉTODO DE RESOLUÇÃO	30
5.1	DETERMINAÇÃO DA MALHA AÉREA	30
5.2	SELEÇÃO DAS AERONAVES	31

5.3	DETERMINAÇÃO DO CASK	32
5.4	MODELO MATEMÁTICO	33
5.5	ADAPTAÇÃO DO MODELO MATEMÁTICO	36
6	IMPLEMENTAÇÃO DO MÉTODO DE RESOLUÇÃO	38
6.1	ENTRADA DO MÉTODO	38
6.2	SAÍDA DO MÉTODO	39
6.3	IMPLEMENTAÇÃO	40
6.3.1	RESOLVEDOR MATEMÁTICO E FERRAMENTAS UTILIZADAS	40
6.3.2	FUNCIONAMENTO DA APLICAÇÃO	40
7	RESULTADOS	42
7.1	FONTES DE DADOS E AMBIENTE COMPUTACIONAL	42
7.2	MALHA AÉREA	43
7.3	CENÁRIOS	45
7.3.1	PRIMEIRO CENÁRIO	46
7.3.2	SEGUNDO CENÁRIO	47
7.3.3	TERCEIRO CENÁRIO	48
7.3.4	QUARTO CENÁRIO	49
7.3.5	QUINTO CENÁRIO	50
7.3.6	SEXTO CENÁRIO	51
7.4	ANÁLISE DOS RESULTADOS	52
8	CONCLUSÃO	53
	REFERÊNCIAS	55

1. INTRODUÇÃO

A aviação atualmente desempenha um papel essencial no desenvolvimento econômico e social (PEROVIC, 2013). Sua capacidade de movimentar cargas e passageiros de forma eficiente e rápida, favorece tanto o turismo quanto o comércio (SANTOS; SILVA, 2019). A aviação regional, por sua vez, destaca-se como um componente estratégico para integrar áreas interioranas e acelerar o desenvolvimento local, especialmente em países com dimensões continentais como o Brasil.

No Brasil, o mercado da aviação regional enfrenta alguns desafios, mas também oferece várias oportunidades únicas. Segundo dados do Painel de Indicadores do Transporte Aéreo (ANAC, 2024b), em 2023 as três grandes companhias aéreas do país detiveram participação de 99,5% do mercado da aviação nacional, sendo suas operações principalmente concentradas em grandes centros urbanos. Isso quer dizer que apenas 0,5% da participação do mercado doméstico é resultado da atuação de companhias aéreas regionais. Esses dados realçam a necessidade de estratégias que ampliem a malha regional para atender as demandas de regiões menos favorecidas.

Nesse contexto, uma malha aérea bem definida constitui um elemento essencial para garantir à companhia aérea a eficiência operacional e aumentar a conectividade no país (BAZARGAN, 2010). Para isso, a utilização de técnicas computacionais avançadas, como a programação linear inteira, mostra-se indispensável na definição de malhas aéreas e na alocação de frotas de forma eficiente. No trabalho de Jesus (2019), por exemplo, a aplicação de um modelo matemático possibilitou a identificação de rotas viáveis, e a seleção das aeronaves adequadas para uma nova companhia aérea com *hub* em Goiânia, destacando o potencial dessas ferramentas.

Além disso, é inegável que a aviação regional no Brasil possui um grande potencial, especialmente por se tratar de um país com dimensões continentais. O investimento em rotas regionais não apenas amplia a conectividade, mas também contribui para o desenvolvimento socioeconômico das regiões atendidas.

Porém, as operações em mercados regionais podem ser um tanto quanto desafiadoras. A busca por um equilíbrio entre os custos operacionais e as demandas em regiões de menor densidade populacional requer planejamentos estratégicos. No caso de uma nova companhia aérea com *hub* em Chapecó, definir rotas financeiramente viáveis e alocar as aeronaves adequadas são tarefas complexas, as quais exigem uma modelagem precisa e adaptada às particularidades do cenário.

1.1 Problema

O problema de pesquisa do presente trabalho foi de identificar se era possível, de forma a maximizar a lucratividade, utilizar um modelo matemático para definir a malha aérea e selecionar as aeronaves a serem utilizadas por uma companhia aérea regional com *hub* em Chapecó. Essa questão surgiu da necessidade de preencher lacunas no mercado regional brasileiro, buscando soluções eficientes utilizando ferramentas de otimização que auxiliem na tomada de decisões estratégicas.

1.2 Objetivos

1.2.1 Objetivo geral

O objetivo deste trabalho foi de selecionar e adaptar um modelo de programação linear inteira para resolver o problema de definição da malha aérea e escolha das aeronaves para uma nova companhia aérea com *hub* em Chapecó. Esse modelo buscou maximizar a lucratividade e a eficiência operacional da companhia.

1.2.2 Objetivos específicos

- Compreender conceitos importantes para o planejamento e definição de malhas aéreas, bem como a seleção de frotas para empresas de aviação civil.
- Pesquisar e selecionar um modelo de programação linear inteira previamente aplicado à definição de malhas aéreas e à alocação de frotas.
- Adaptar e implementar a resolução do modelo, ajustando-o para que este atenda às especificidades e objetivos da presente pesquisa.
- Analisar os resultados obtidos para avaliar a viabilidade das rotas da malha aérea final e a adequação das aeronaves alocadas para cada rota.

1.3 Justificativa

Com o impulso crescente na aviação regional brasileira (MPOR, 2024), surge a necessidade de expansão e/ou diversificação dos *hubs* aeroportuários, o que leva a uma descentralização das operações nos grandes aeroportos, trazendo grandes benefícios ao setor. Novas opções de *hub* são fundamentais para a redução da concentração do tráfego aéreo em aeroportos sobrecarregados, trazendo assim melhoras significativas na eficiência operacional, além de um aumento na conectividade entre as regiões do país.

Além disso, novos *hubs* influenciam economicamente de forma expressiva as regiões próximas dos novos centros de operação, gerando novos empregos, estimulando o turismo e desenvolvimento local. Este impacto não se limita apenas no setor de transporte, mas se estende também ao desenvolvimento econômico, infraestrutura, podendo até mesmo aumentar a demanda e atrair mais usuários para a aviação regional.

No entanto, percebe-se que o problema de alocação de frotas (FAP) tem sido aplicado em estudos focados em outras regiões do Brasil, deixando uma lacuna quanto à aplicação deste modelo em cidades do sul do país.

1.4 Resultados obtidos

Ao longo desta pesquisa, foi selecionado, adaptado e implementado um modelo matemático baseado em programação linear inteira, originalmente proposto por Jesus (2019), com o objetivo de auxiliar a definição da malha aérea e a seleção das aeronaves para uma nova companhia aérea regional com *hub* em Chapecó. O modelo foi implementado na linguagem de programação Python, utilizando o resolvidor matemático Gurobi. Além disso, uma nova restrição relacionada à superfície da pista dos aeródromos foi adicionada ao modelo, com o intuito de torná-lo mais robusto e representar de forma mais realista as limitações operacionais da aviação regional brasileira.

As simulações foram realizadas utilizando dados reais disponibilizados por órgãos oficiais, com foco nos anos de 2019 e 2024. As informações utilizadas englobaram demanda de passageiros, tarifas médias, características técnicas das aeronaves e infraestrutura dos aeródromos. O custo por assento-quilômetro foi calculado com base na metodologia utilizada anteriormente por Pereira (2021), a partir de um

modelo de regressão linear, utilizando dados do ano de 2019 para ambos os anos devido à indisponibilidade de dados atualizados.

Foram definidos seis cenários operacionais distintos, variando a quantidade máxima de tipos de aeronaves disponíveis para o modelo alocar para atender a malha aérea. Os resultados mostraram que a diversificação da frota teve um impacto positivo sobre o lucro, e é indispensável para a viabilidade das operações. Observou-se também que, em todos os cenários viáveis, o modelo selecionou jatos regionais, especialmente em rotas com maior demanda e/ou maior distância, e aeronaves utilitárias leves para complementar as operações da companhia aérea.

Conclui-se que o modelo foi capaz de gerar, de forma consistente, resultados condizentes com a realidade da aviação regional no Brasil. A abordagem adotada mostrou-se eficaz para o apoio à tomada de decisões estratégicas no planejamento de malhas aéreas e na definição de frotas, demonstrando um grande potencial de aplicação prática.

2. FUNDAMENTAÇÃO TEÓRICA

O presente capítulo tem por objetivo apresentar os principais conceitos teóricos necessários para o desenvolvimento desta pesquisa. Serão abordados temas relacionados a métodos de otimização e técnicas matemáticas aplicadas ao planejamento de operações da aviação civil, além de explorar métricas e indicadores utilizados na indústria atualmente.

2.1 Mercado da Aviação Regional

O mercado de aviação regional é a parte da aviação civil que conecta cidades menores às grandes metrópoles, de modo a atender regiões com infraestrutura aeroportuária limitada ou com demanda baixa de passageiros. Esse mercado desempenha um papel crucial na comunidade, pois a conexão com centros urbanos facilita o desenvolvimento econômico dessas regiões interioranas (BETTINI, 2007). Uma das características da aviação regional é o uso de aeronaves de pequeno porte, pois grande parte dos aeródromos não possui demanda e/ou infraestrutura para receber um grande número de passageiros. Por exemplo, a aviação regional no Brasil conecta cidades como Chapecó a grandes cidades como Florianópolis e São Paulo, permitindo que passageiros dessa região tenham acesso ao restante do país e até mesmo ao exterior.

De acordo com o Ministério de Portos e Aeroportos (MPOR, 2024), a aviação regional brasileira seria impulsionada até o final de 2024 com a inclusão de 13 novas aeronaves Embraer do modelo E195-E2 (EMBRAER, 2024), maior e mais moderno jato da fabricante, à frota de uma das grandes companhias aéreas do país. Esta aeronave possui capacidade de transportar até 136 passageiros e permite a companhia aérea operar em aeródromos com menor infraestrutura aeroportuária, além de ser uma das melhores opções hoje na categoria de jatos comerciais com até 150 assentos.

2.2 Conceitos da Aviação Civil

A aviação civil é um setor que possui um amplo conjunto de conceitos técnicos que são fundamentais para a operação eficiente e segura das companhias aéreas.

Esses conceitos envolvem desde aspectos de infraestrutura, até métricas financeiras que avaliam o desempenho e viabilidade econômica das rotas.

2.2.1 Agência Nacional de Aviação Civil - ANAC

A Agência Nacional de Aviação Civil (ANAC) é uma agência reguladora federal, responsável pela regulação e fiscalização das atividades da aviação civil no Brasil. Criada em 2005, a ANAC (2024a) iniciou suas atividades em 2006, substituindo o até então Departamento de Aviação Civil (DAC), com o objetivo de proporcionar uma administração mais técnica e autônoma para a aviação civil no país.

A certificação de novas aeronaves é um exemplo prático da atuação da ANAC. Antes de qualquer novo modelo de aeronave entrar em operação no país, a ANAC executa um processo rigoroso de certificação para garantir que esta cumpra todos os padrões de segurança exigidos internacionalmente, resultando em um cenário cada vez mais seguro.

2.2.2 Aeródromo

O aeródromo, como definido pela ANAC (2021), é uma área específica destinada a operações como pouso, decolagem e movimentação de aeronaves, e pode estar em terra ou água. Já o aeroporto é um aeródromo com instalações e equipamentos que dão apoio às operações de transporte de pessoas e cargas.

2.2.3 *Hub and spoke*

O modelo *hub and spoke* é uma estrutura de malha aérea utilizada para otimizar a operação das companhias aéreas. Nesse modelo, um ou mais aeroportos são escolhidos para serem os pontos centrais ou *hubs*, se conectando a diversos outros aeródromos que são chamados de *spokes*, e todas as empresas possuem pelo menos um de cada. O *hub* além de se conectar com os *spokes*, pode servir como base de apoio para as aeronaves, então é normal que as manutenções das mesmas sejam feitas nele.

Visualmente, a estrutura *hub and spoke* pode ser comparada com uma roda de bicicleta, onde o *hub* se encontra no centro da roda, e os raios são as rotas que

ligam este aos *spokes*. A estrutura *hub and spoke* pode ser dividida em duas estratégias: a *hub and spoke* pura e a híbrida. Na configuração pura, os *spokes* são conectados exclusivamente aos *hubs*, centralizando todas as operações no *hub*. Já na configuração híbrida, os *spokes* podem se conectar tanto aos *hubs* quanto diretamente a outros *spokes*, proporcionando mais flexibilidade e opções de conexão entre os aeroportos. Exemplo das duas estratégias *hub and spoke* são mostrados na Figura 2.1.




Figura 2.1 – a) Rede *hub and spoke* pura. b) Rede *hub and spoke* híbrida – adaptado de uma figura de Choi, Lee e Park (2018).

2.2.4 Malha aérea

A malha aérea nada mais é do que um conjunto de rotas que conectam diferentes aeroportos. Todas as companhias aéreas precisam de uma malha bem definida, considerando as estratégias da empresa. Além disso, a malha aérea deve ser planejada de modo a maximizar a eficiência e cobertura das operações da companhia. Um exemplo de malha aérea pode ser visto na Figura 2.2.

Existem diferentes configurações de malha aérea, mas o *hub and spoke* e o ponto a ponto se destacam. Como já visto, o *hub and spoke* possui um aeroporto central que se conecta a vários outros. Já o ponto a ponto conecta duas cidades diretamente, sem a necessidade de passar por um *hub*.

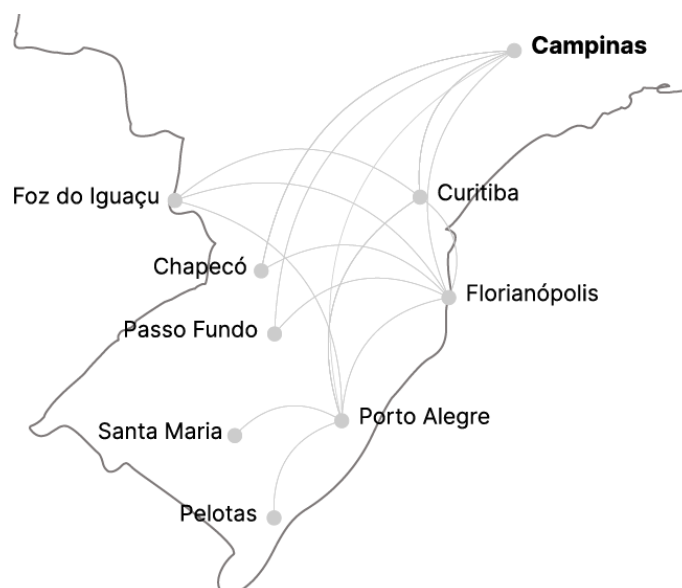


Figura 2.2 – Uma malha aérea com um *hub* e oito *spokes*, adaptado de Azul (2024)

2.2.5 Receita Operacional Total

A receita operacional total (TOR, do inglês *Total Operating Revenue*) é a combinação de todas as receitas geradas pelas operações de uma companhia aérea, por exemplo, venda de passagens, transporte de cargas, vendas a bordo, entre outras fontes de receita ligadas às operações de voo. Esta métrica é crucial para a avaliação do desempenho econômico da empresa (GILLEN, 2020).

2.2.6 Receita por Passageiro-Quilômetro

A receita por passageiro-quilômetro (RPK, do inglês *Revenue Passenger Kilometers*), é um indicador utilizado para mensurar a receita gerada por quilômetro voado com assentos vendidos (NYGREN; ALEKLETT; Höök, 2009). Essa métrica é calculada multiplicando o número de assentos vendidos pela distância voada. Em uma rota popular, por exemplo, a RPK tende a ser alta devido à sua demanda e frequência de voos. Por outro lado, em rotas menos populares a RPK tende a ser menor.

2.2.7 Custos Operacionais Totais

Os custos operacionais totais (TOC, do inglês *Total Operating Costs*), como o nome sugere, representam todos os custos envolvidos na operação de uma companhia aérea (SWAN; ADLER, 2006). Essa métrica é essencial para a empresa avaliar a lucratividade e até mesmo a viabilidade da rota.

2.2.8 Assento-Quilômetro Disponível

O Assento-quilômetro disponível (ASK, do inglês *Available Seat Kilometer*), é um indicador utilizado para analisar a capacidade de atendimento anual da companhia aérea, ou a disponibilidade de assentos durante o ano, segundo Bazargan (2010). O ASK é calculado multiplicando o número de assentos disponíveis na aeronave pela distância percorrida em quilômetros na rota. Este dado também é utilizado para calcular o custo por assento-quilômetro, que será explicado a seguir.

2.2.9 Custo por Assento-Quilômetro

Outra métrica fundamental para companhias aéreas é o custo por assento-quilômetro (CASK, do inglês *Cost per Available Seat Kilometer*), que é um dos custos operacionais de cada voo realizado pela empresa (MOTTA et al., 2020). O cálculo realizado para a obtenção do CASK é a divisão dos custos operacionais totais (TOC) pelo assento-quilômetro disponível (ASK).

Em rotas com baixa quantidade de assentos ocupados, por exemplo, o CASK tende a ser maior, pois os custos são diluídos entre poucos passageiros. Já em rotas com alta taxa de ocupação, o contrário acontece, pois os custos são distribuídos entre um número maior de passageiros.

2.2.10 Yield

O *yield* é um indicador financeiro que aponta quanto uma companhia aérea ganha por quilômetro voado em cada assento vendido (BAZARGAN, 2010), então quanto maior, melhor será a receita gerada pela rota. Esta métrica é muito importante

pois ajuda as empresas a avaliar a lucratividade das rotas, comparando a receita com os custos de operação.

Por exemplo, em rotas com alta demanda de passageiros, o *yield* tende a ser maior, pois como a procura é maior, a precificação pode ser mais elevada. Um exemplo claro é a ponte aérea Rio-São Paulo, que liga os aeroportos Santos Dumont, no Rio de Janeiro, e Congonhas, em São Paulo.

2.3 Pesquisa Operacional

É comum que empresas enfrentem desafios constantes na alocação de recursos de forma eficiente, especialmente em setores complexos como o da aviação. Para isso, é adequada uma metodologia que, de acordo com Arenales et al. (2006), surgiu na Segunda Guerra Mundial para otimizar operações militares e distribuir recursos de forma mais eficiente. Esta metodologia é conhecida atualmente como pesquisa operacional (PO), e ela oferece várias ferramentas e métodos matemáticos que auxiliam na resolução desses problemas.

Com a utilização de técnicas como a programação linear inteira e análise de simulações, a PO possibilita que companhias aéreas transformem questões complexas em modelos matemáticos estruturados, possibilitando a obtenção de soluções práticas e otimizadas. Exemplo disso é o problema de escalonamento de tripulações (CSP, do inglês *Crew Scheduling Problem*), que consiste em alocar pilotos e comissários de bordo aos voos de forma adequada, considerando todos os requisitos regulamentares de descanso e carga horária. Neste caso, a PO pode contribuir na redução de custos operacionais, garantindo um uso eficiente da equipe.

Por fim, a pesquisa operacional é uma ferramenta essencial na tomada de decisões estratégicas em companhias aéreas, pois possibilita a criação de malhas aéreas eficientes, a redução de custos operacionais e a maximização dos lucros.

2.3.1 Programação Linear Inteira

É comum que empresas aéreas enfrentem problemas de decisão complexos, e por vezes, necessitem que as variáveis de decisão sejam números inteiros, já que não seria real 1/3 de uma aeronave realizar um voo. Desta maneira, a programação linear inteira (PLI) surge como uma técnica poderosa, que permite a utilização de variáveis que assumem apenas valores inteiros, situação comum em cenários de

planejamento operacional. Diferente da programação linear, onde as variáveis podem assumir valores fracionários, a PLI aplica restrições que tornam o modelo mais realista, viabilizando a aplicação deste em problemas de otimização. Apesar de não parecer uma alteração substancial, resolver um problema de programação linear inteira é significativamente mais difícil do que resolver um problema de programação linear (NEMHAUSER; WOLSEY, 1999).

A programação linear inteira envolve a identificação das variáveis de decisão, da função objetivo e das restrições. Essas etapas permitem uma modelagem do problema de forma que as soluções encontradas atendam os critérios e limitações operacionais, fornecendo resultados práticos e aplicáveis. No Capítulo 5, será apresentado em detalhes um modelo matemático de programação linear inteira para o problema de definição da malha aérea e alocação de aeronaves, o qual foi implementado nesta pesquisa.

2.4 Problema de Alocação de Frota

O problema de alocação de frota (FAP, do inglês *fleet assignment problem*), é um problema que tem por objetivo tornar possível a alocação de diferentes tipos de aeronaves a rotas específicas, buscando maximizar a eficiência e minimizar os custos operacionais da companhia aérea. Como dito por Medau (2017), o problema deve considerar tanto as características das aeronaves, quanto as características das rotas. Uma técnica amplamente utilizada para a resolução do FAP é a programação linear inteira, pois ela permite a modelagem das restrições e necessidades de forma precisa.

Nos dias atuais, normalmente as companhias aéreas possuem aviões de diferentes tipos e tamanhos. Tal variedade proporciona a elas a capacidade de operar tanto em aeródromos menores, geralmente situados em cidades do interior, quanto em aeródromos maiores, geralmente situados em metrópoles. Tendo isso em mente, o FAP ajuda a determinar quais aeronaves devem ser utilizadas em cada rota.

3. TRABALHOS RELACIONADOS

Neste capítulo, serão apresentados estudos e pesquisas que possuem relação direta com o tema do presente trabalho, permitindo a análise das metodologias e resultados obtidos em trabalhos anteriores. Esses trabalhos envolvem o uso de pesquisa operacional, programação linear inteira, métodos de otimização e a aplicação de *softwares* de modelagem matemática, como COIN-OR e LINGO. Essas ferramentas são utilizadas para a resolução de problemas complexos, como a alocação de frotas e definição de malhas aéreas. A análise desses estudos contribuiu para a construção de uma base sólida para a pesquisa atual.

Em seu trabalho, Pereira (2021) propõe uma metodologia baseada em programação linear inteira para resolver o problema de alocação de frotas em uma malha aérea regional do tipo *hub-spoke*. O autor considera parâmetros como o custo por assento-quilômetro (CASK) e o *yield*, utilizando dados disponíveis na plataforma Hórus (SAC, 2024), fornecida pelo Ministério da Infraestrutura do Brasil. Relata-se que não foi possível simular todos os cenários desejados devido a limitações computacionais. Mesmo assim, com os resultados obtidos, é possível observar que a metodologia de otimização contribui na redução de custos operacionais e na melhora da eficiência no uso de aeronaves nas rotas estudadas. Também, entre os resultados obtidos, o autor conseguiu definir uma malha aérea preliminar otimizada, além da escolha das aeronaves ideais para as diferentes rotas, levando em consideração os custos operacionais e a demanda de passageiros de cada destino.

Jesus (2019) teve como objetivo modelar um processo para definir a malha aérea de uma nova companhia regional, e selecionar as melhores aeronaves para o segmento, com foco em maximizar a lucratividade. O autor utilizou dados coletados junto a representantes da Embraer e da ANAC (ANAC, 2024a), aplicando uma metodologia baseada no *Design Science Research*. Desenvolveu e validou diferentes cenários de rotas e frotas através da modelagem computacional, utilizando o *software* LINGO (LINDO, 2024). Os resultados obtidos no trabalho revelaram a definição dos melhores destinos e a melhor combinação de aeronaves, considerando a demanda e os custos operacionais. Notou-se na pesquisa que em companhias aéreas regionais, há uma tendência grande na utilização de aeronaves de menores portes, já que estas possuem probabilidades maiores na questão da lucratividade máxima. Também, o estudo destaca que há um grande potencial de crescimento do mercado de aviação regional no Brasil, e um planejamento eficiente é importante para garantir a lucratividade da nova companhia.

Já o estudo de Felipe (2022) aborda a questão da alocação de frotas em rotas regionais no Brasil com o foco na redução da complexidade computacional envolvida nesse processo, utilizando o método de programação linear inteira mista. Ademais, foram propostas melhorias para que fosse possível alocar até cinco aeronaves simultâneas. A autora utilizou em sua pesquisa um cenário composto por 12 *hubs*, 710 rotas e 6 tipos diferentes de aeronaves. Uma das principais contribuições foi a inclusão do fator de ocupação (*load factor*), o qual eliminou situações em que aeronaves de grande porte realizem voos com poucos passageiros a bordo. Os resultados da pesquisa mostraram que o modelo matemático proposto foi capaz de gerar uma malha aérea otimizada para a alocação de aeronaves. Além disso, os cenários simulados mostraram a capacidade do modelo em alocar até cinco aeronaves simultaneamente, gerando um lucro muito significativo no cenário mais complexo.

Na pesquisa de Cortez, Colucci e Sá (2012), o objetivo geral foi aplicar métodos de otimização e heurísticas para resolver o problema da determinação de viagens no cenário da aviação comercial brasileira. Os principais resultados indicam que a heurística de busca local mostrou-se eficiente para todos os tamanhos, produzindo soluções ótimas para instâncias de pequeno e médio porte, e soluções próximas ao ótimo para instâncias com grande volume de voos. O algoritmo genético, por sua vez, mostrou-se inviável para instâncias maiores, e ineficiente para as menores. O autor relata que, mesmo após a utilização de uma versão híbrida, combinando o algoritmo genético com a busca local, os resultados não se modificaram, e os ganhos são inexpressivos. Já o método de geração de colunas obteve soluções ótimas para todos os cenários simulados, sendo este o método mais promissor para instâncias com muitos voos, já que o mesmo consegue entregar ótimos resultados com poucas iterações.

Os trabalhos relacionados apresentados acima possuem semelhanças significativas com o presente estudo, uma vez que a maioria faz uso de métodos de otimização e programação linear inteira. Além disso, o uso de uma linguagem de programação amplamente utilizada, como *Python* ou *Java*, também está alinhada com a proposta do presente trabalho. Entretanto, algumas diferenças se destacam. No estudo de Felipe (2022), o foco foi na redução da complexidade computacional, propondo melhorias no modelo matemático para que fosse possível alocar várias aeronaves simultaneamente, enquanto o presente trabalho focou na definição de uma malha aérea e na seleção de aeronaves para uma nova companhia baseada em Chapecó, uma abordagem mais simplificada. Adicionalmente, a utilização de heurísticas como métodos de busca local e geração de colunas presentes no trabalho de Cortez, Colucci e Sá (2012) não estão presentes aqui, uma vez que o objetivo foi a aplicação direta de programação linear inteira para atingir a solução desejada. Já o estudo de Jesus

(2019) é o que apresenta semelhanças mais significativas com o presente estudo, sendo a cidade considerada como *hub* a maior diferença entre os dois trabalhos.

4. METODOLOGIA

Para que fosse possível a realização do presente trabalho, as seguintes etapas foram executadas:

1. **Revisão bibliográfica:** A revisão bibliográfica realizada neste projeto reuniu estudos relevantes sobre a definição de malhas aéreas, alocação de frotas e métodos de otimização aplicados ao cenário da aviação. Além disso, a revisão bibliográfica contribuiu para o entendimento das práticas e metodologias mais eficazes, orientando as demais etapas do trabalho.
2. **Definir os elementos do cenário considerado:** Esta etapa envolveu a identificação dos principais parâmetros do cenário, incluindo a seleção de possíveis destinos, a escolha das aeronaves candidatas a serem alocadas para as rotas, e a definição dos custos operacionais que influenciam diretamente o modelo. Nesta etapa, foram utilizados os dados disponíveis nas plataformas Hórus (SAC, 2024) e DataSAS (ANAC, 2025a).
3. **Selecionar um modelo:** A escolha de um modelo que tenha se mostrado viável em contextos de definição de malhas aéreas e alocação de frotas é extremamente importante, já que este define se os resultados são eficientes e realistas. A seleção de um modelo adequado permitiu a representação de restrições operacionais, maximizando a eficiência da malha aérea resultante e otimizando os recursos da empresa. O objetivo foi seguir o modelo proposto por Jesus (2019), o qual apresentou bons resultados, e que pôde ser facilmente adaptado conforme as necessidades para atender os requisitos do cenário do presente estudo.
4. **Adaptar o modelo:** Nesta etapa, não foram necessários ajustes referentes às restrições existentes no modelo de Jesus (2019), já que as mesmas já estavam de acordo com a realidade do *hub* em Chapecó. No entanto, com o objetivo de agregar maior realismo ao modelo, foi incorporada uma nova restrição relacionada à compatibilidade entre os tipos de aeronaves e as superfícies das pistas dos aeródromos de destino, a qual pode ser visualizada de forma detalhada no Seção 5.5.
5. **Implementar a resolução do modelo:** O objetivo desta etapa foi validar se o modelo estava funcionando corretamente, e garantir que ele pudesse fornecer soluções adequadas para a definição da malha aérea e a alocação de frotas. O modelo foi implementado através de um resolvedor matemático para que fossem simulados diferentes cenários de demanda e operação. O resolvedor utilizado

foi o Gurobi (GUROBI, 2025), que, além de oferecer um bom desempenho, possui uma licença gratuita para acadêmicos que pôde ser facilmente solicitada. A implementação do modelo foi realizada utilizando a linguagem de programação Python, já que é possível obter bons resultados em pouco tempo, e possibilitou a utilização do resolvidor matemático Gurobi através de uma interface.

6. **Analisar os resultados:** A análise dos resultados consistiu na avaliação das malhas aéreas resultantes, verificando a configuração das rotas conforme a demanda de passageiros, e a avaliação da aplicabilidade das aeronaves selecionadas para cada rota. Esta etapa também validou a viabilidade das rotas por meio do indicador financeiro CASK.

5. MÉTODO DE RESOLUÇÃO

Este capítulo apresenta, de forma detalhada, os procedimentos empregados para a construção da malha aérea, seleção das aeronaves, estimativa de custos operacionais e a formulação do modelo matemático utilizado. As decisões metodológicas adotadas visam garantir a viabilidade técnica e econômica da proposta, garantindo que os resultados obtidos sejam próximos das condições reais de operação do transporte aéreo regional. Além disso, é descrita uma adaptação realizada no modelo original, feita com o objetivo de incorporar uma nova restrição relevante para a ampliação da sua capacidade de representação da realidade operacional.

5.1 Determinação da malha aérea

A malha aérea utilizada nesta pesquisa foi montada a partir de dados públicos disponibilizados no portal DataSAS, plataforma mantida pela ANAC (2025a). Esse portal reúne informações detalhadas sobre as tarifas do transporte aéreo doméstico de passageiros, incluindo dados mensais sobre origem, destino, quantidade de assentos vendidos e tarifas médias praticadas.

Dentre todas as informações presentes nos arquivos obtidos do portal, foram considerados apenas os registros com origem no aeroporto de Chapecó (SBCH), já que apenas esses dados são necessários para o desenvolvimento deste trabalho. Os dados, organizados de forma mensal, foram agrupados para uma base anualizada, resultando, para cada registro, no total de assentos vendidos e a tarifa média anual. Esse procedimento foi realizado isoladamente para os anos de 2019 e 2024, anos selecionados para a realização das simulações.

Uma vez obtida a base anualizada, procedeu-se à conversão das demandas anuais em valores semanais, com o objetivo de obter um planejamento de alocação semanal de aeronaves às rotas. Esse ajuste foi realizado dividindo-se a demanda anual de cada rota pelo número aproximado de semanas que um ano possui (52 semanas). A tarifa média anual foi mantida como representativa de todo o ano, uma vez que esta foi calculada a partir dos dados agregados dos doze meses.

A última etapa consistiu na aplicação de um critério de corte, com o objetivo de extrair apenas as rotas consideradas economicamente viáveis. Foram selecionadas apenas aquelas cuja demanda semanal média fosse igual ou superior a seis

passageiros, valor definido com base em mais da metade da capacidade de assentos da menor aeronave (nove assentos) considerada nas simulações.

5.2 Seleção das aeronaves

A seleção das aeronaves consideradas nas simulações foi realizada com base em dois critérios principais: a presença da aeronave no mercado brasileiro, e o potencial de operação da mesma no contexto regional nacional. O objetivo foi de compor um conjunto de aeronaves com possibilidades reais de operação, respeitando as características operacionais e comerciais do setor aéreo do país.

O primeiro critério considerou aeronaves que já operam no Brasil, tanto em operações regulares quanto em operações regionais. Esse grupo compreende modelos como o ATR 72-600, a família Embraer E-Jets, o Cessna 208B Grand Caravan EX e o Airbus A320neo. A utilização de modelos já presentes no setor aéreo nacional contribui para maior viabilidade operacional, já que essas aeronaves são compatíveis com a infraestrutura aeroportuária nacional e com os procedimentos operacionais já consolidados no país.

O segundo critério abrangeu aeronaves que, embora ainda não estejam presentes ou amplamente difundidas no mercado brasileiro, apresentam elevado potencial para operação regional. Foram incluídos modelos modernos e eficientes, com desempenho compatível com a malha aérea proposta, como o Cessna 408 SkyCourier, a família Airbus A220 e o Boeing 737 MAX 7. Essas aeronaves têm se destacado por sua eficiência operacional, baixo consumo de combustível, modernização tecnológica e boa relação entre capacidade e desempenho, tornando-as opções atrativas para diferentes perfis de operação.

As aeronaves selecionadas para compor o conjunto de alternativas para o modelo estão apresentadas na Tabela 5.1. Para cada aeronave, são descritos o modelo (junto com o fabricante), o número de assentos, a autonomia máxima de voo (em quilômetros) e o comprimento mínimo de pista (em metros) necessário para operação. O número de assentos considerado corresponde à configuração com duas classes, conforme especificado pelos fabricantes, por ser a mais comum em operações de companhias aéreas regionais. Já para os modelos que não oferecem essa configuração, optou-se pela capacidade em classe única. A autonomia máxima de voo e o comprimento mínimo de pista referem-se às especificações fornecidas também pelos fabricantes para o peso máximo de decolagem.

Tabela 5.1 – Aeronaves candidatas para o modelo

Modelo	Assentos	Autonomia (km)	Pista Mínima (m)
Airbus A319neo	150	6.850	1.750
Airbus A320neo	180	6.300	1.951
Airbus A220-100	120	6.700	1.463
Airbus A220-300	150	6.300	1.890
ATR 42-600	48	1.345	1.107
ATR 72-600	72	1.370	1.315
Boeing 737 MAX 7	126	7.037	2.083
Boeing 737 MAX 8	162	6.704	2.490
Cessna 208B Grand Caravan EX	9	1.689	426
Cessna 408 SkyCourier	19	1.704	1.116
Embraer E175-E2	80	3.704	1.730
Embraer E190-E2	97	5.463	1.615
Embraer E195-E2	120	5.556	1.840
Pilatus PC-12 NGX	9	1.285	758

5.3 Determinação do CASK

O custo por assento-quilômetro (CASK), como citado anteriormente (Seção 2.2.9), representa uma das principais métricas para a análise de viabilidade econômica das operações aéreas. Sua determinação é fundamental para o cálculo dos custos operacionais no modelo proposto.

Nesta pesquisa, considerou-se a mesma metodologia de cálculo apresentada por Pereira (2021), que consiste na utilização de um modelo de regressão linear baseado na função de Cobb-Douglas.

Como explicado adiante na Seção 7.1, os experimentos realizados neste trabalho foram conduzidos com base em dados dos anos de 2019 e 2024. Porém, devido à indisponibilidade de dados atualizados na plataforma Hórus para o ano de 2024, os valores de CASK utilizados neste estudo para ambos os anos foram calculados com base nos dados disponíveis referentes ao ano de 2019.

Após a linearização da função e a aplicação do método dos mínimos quadrados, Pereira obteve os seguintes coeficientes:

$$\ln(C) = 1,728912383 - 0,356708479 \times \ln(S) - 0,404534157 \times \ln(D)$$

onde C representa o custo por assento-quilômetro (CASK), S é o número de assentos da aeronave, e D corresponde à distância da rota (em quilômetros).

Com base nesta equação, o valor do CASK foi calculado para cada combinação de aeronave e rota ao longo deste estudo. A aplicação desse modelo permitiu estimar os custos operacionais com elevada qualidade de ajuste, com o coeficiente de determinação R^2 de aproximadamente 0,973, indicando forte correlação entre as variáveis adotadas no modelo.

5.4 Modelo matemático

Para representar formalmente o problema de definição da malha aérea e alocação de frotas, foi utilizado o modelo de programação linear inteira proposto por Jesus (2019). Esse modelo foi considerado adequado para o cenário simulado neste trabalho por incorporar aspectos econômicos e operacionais reais do setor aéreo regional, como a capacidade das aeronaves, alcance máximo, compatibilidade com a extensão da pista, e a limitação na quantidade de tipos diferentes de aeronaves utilizadas.

A seguir, são descritos os dados de entrada utilizados no modelo:

- O conjunto de destinos $J = \{j_1, j_2, \dots, j_n\}$, onde cada elemento $j \in J$ representa um destino da malha aérea considerada na simulação. Todas as rotas possuem como origem o aeródromo de Chapecó.
- O conjunto de aeronaves $A = \{a_1, a_2, \dots, a_n\}$, onde cada elemento $a \in A$ representa um tipo de aeronave disponível para operação no modelo.
- A tarifa $T_{j,a}$ corresponde ao valor médio pago em reais por passageiro na rota com destino j , quando operada com a aeronave a .
- O valor $C_{j,a}$ refere-se ao CASK da aeronave a na operação até o destino j , também expresso em reais.
- O parâmetro S_a representa a quantidade total de assentos disponíveis na aeronave a .
- A distância D_j indica o percurso em linha reta entre a origem (Chapecó) e o destino j , expressa em quilômetros.
- A demanda Q_j representa o número total de passageiros pagantes transportados semanalmente para o destino j .

- O comprimento mínimo de pista W_a define o menor comprimento de pista necessário para que uma aeronave a – em seu peso máximo de decolagem – possa pousar ou decolar com segurança.
- O parâmetro L_j indica o comprimento efetivo da pista disponível no aeródromo de destino j .
- O alcance R_a indica a distância máxima, em quilômetros, que a aeronave a é capaz de percorrer sem escalas, também em seu peso máximo de decolagem.
- O valor K representa o número máximo de tipos distintos de aeronaves que podem ser utilizadas simultaneamente na solução do modelo.
- O parâmetro Z indica o número máximo de voos que cada modelo de aeronave pode realizar para cada destino.

O modelo possui as seguintes variáveis de decisão:

- A variável inteira $P_{j,a}$ representa o número de passageiros transportados pela aeronave a para o destino j . Conjunto de variáveis: $P_{j,a}, \forall j \in J, \forall a \in A$.
- A variável inteira $F_{j,a}$ indica o número de voos semanais realizados pela aeronave a para o destino j . Conjunto de variáveis: $F_{j,a}, \forall j \in J, \forall a \in A$.
- A variável binária $BIN_{j,a}$ assume o valor 1 se a aeronave a for alocada para atender o destino j , e o valor 0 caso contrário. Conjunto de variáveis: $BIN_{j,a}, \forall j \in J, \forall a \in A$.
- A variável binária $BIN2_a$ assume valor 1 se a aeronave a for utilizada em pelo menos uma rota, e valor 0 caso contrário. Conjunto de variáveis: $BIN2_a, \forall a \in A$.

As restrições do modelo são definidas a seguir:

1. Garante que o número de assentos envolvidos em voos para cada destino atenda à demanda total do destino:

$$\sum_{a \in A} S_a \times F_{j,a} \geq Q_j, \quad \forall j \in J$$

2. Impede que aeronaves sejam alocadas a destinos cuja pista seja menor que o mínimo exigido:

$$W_a \times BIN_{j,a} \leq L_j, \quad \forall j \in J, \forall a \in A$$

3. Restringe a alocação de aeronaves a rotas compatíveis com seu alcance máximo:

$$D_j \times BIN_{j,a} \leq R_a, \quad \forall j \in J, \forall a \in A$$

4. Garante que o número de voos de uma aeronave seja menor que um determinado limite quando ela estiver alocada a um destino:

$$F_{j,a} \leq Z \times BIN_{j,a}, \quad \forall j \in J, \forall a \in A$$

5. Limita o número de tipos distintos de aeronaves utilizadas por destino:

$$\sum_a BIN_{j,a} \leq K, \quad \forall j \in J$$

6. Garante que, se uma aeronave for utilizada em uma rota, seu fluxo não ultrapasse um determinado limite:

$$F_{j,a} \leq Z \times BIN2_a, \quad \forall j \in J, \forall a \in A$$

7. Restringe o número total de tipos de aeronaves utilizadas em toda a malha aérea:

$$\sum_a BIN2_a \leq K$$

8. Garante que o número total de passageiros para um destino seja igual à demanda:

$$\sum_{a \in A} P_{j,a} = Q_j, \quad \forall j \in J$$

9. Impede que o número de passageiros transportados exceda a capacidade da aeronave:

$$P_{j,a} \leq S_a \times F_{j,a}, \quad \forall j \in J, \forall a \in A$$

A função objetivo do modelo é dada por:

$$\max \sum_{j \in J} \sum_{a \in A} (T_{j,a} \times P_{j,a} - C_{j,a} \times S_a \times D_j \times F_{j,a})$$

Esta função busca maximizar o lucro operacional da companhia aérea, obtido pela diferença entre a receita obtida com a venda de passagens e os custos operacionais estimados. A receita é representada pelo produto da tarifa média $T_{j,a}$ e o número de passageiros transportados $P_{j,a}$. O custo operacional é calculado utilizando o valor do

CASK $C_{j,a}$, multiplicado pelo número de assentos da aeronave S_a , pela distância da rota D_j e pelo número de voos realizados $F_{j,a}$.

5.5 Adaptação do modelo matemático

Considerando o contexto abordado nesta pesquisa, foi realizada uma adaptação do modelo de Jesus (2019) com o intuito de incorporar uma restrição adicional relacionada às características de infraestrutura dos aeródromos. Especialmente, buscou-se garantir que cada aeronave seja alocada apenas a destinos cuja superfície da pista seja compatível com sua operação.

Inicialmente, considerou-se a possibilidade de utilizar as classificações de resistência das pistas dos aeródromos (como o índice PCN – número de classificação do pavimento, do inglês *Pavement Classification Number*) em conjunto com os limites de peso das aeronaves (ACN – número de classificação da aeronave, do inglês *Aircraft Classification Number*) como critério técnico para verificar a compatibilidade operacional. Entretanto, devido à indisponibilidade de alguns dados e à limitação de tempo no desenvolvimento da pesquisa, optou-se por uma abordagem mais simplificada.

Assim, foi incluída no modelo uma nova restrição baseada em uma classificação ordinal da superfície das pistas. Os valores de superfície foram representados por inteiros em ordem crescente, conforme definido na Tabela 5.2.

Tabela 5.2 – Classificação de superfícies

Classificação	Superfície
0	Desconhecido
1	Areia
2	Grama
3	Terra
4	Saibro
5	Cascalho
6	Piçarra
7	Asfalto
8	Concreto

Para cada aeronave, foi definida a superfície mínima exigida para sua operação segura, e, para cada aeródromo, foi atribuída a classificação correspondente à superfície predominante da pista. A compatibilidade é garantida por meio da seguinte restrição:

$$T_j \geq M_a \times BIN_{j,a}, \quad \forall j \in J, \forall a \in A$$

Essa restrição assegura que a aeronave a somente poderá ser alocada ao destino j se a superfície da pista T_j do aeródromo for igual ou superior à superfície M_a exigida por aquele modelo de aeronave.

6. IMPLEMENTAÇÃO DO MÉTODO DE RESOLUÇÃO

Este capítulo descreve a implementação computacional do método de resolução proposto na presente pesquisa, detalhando as etapas necessárias para transformar o modelo matemático, dados de entrada e restrições operacionais em uma aplicação funcional. Além disso, será apresentada a arquitetura geral da aplicação, com destaque para as bibliotecas utilizadas, o resolvidor matemático empregado e o fluxo de execução do programa.

6.1 Entrada do método

O método desenvolvido na presente pesquisa depende de um conjunto estruturado de dados de entrada, cuja leitura, organização e serialização constituem a primeira etapa do processo de resolução. Esses dados estão armazenados em arquivos nos formatos *.xlsx* e *.json*, contendo informações como características operacionais das aeronaves, dados sobre os aeródromos públicos nacionais, e informações consolidadas de demanda e tarifas médias por origem e destino.

As informações presentes em planilhas, como os valores médios de tarifas e características das aeronaves, foram lidas e processadas com o auxílio da biblioteca *pandas* (versão 2.2.0), que permitiu a execução de operações como a filtragem de dados. Os arquivos estruturados em formato *.json*, contendo informações sobre os aeroportos (como localização, infraestrutura e atributos operacionais), foram manipulados por meio do módulo nativo *json* do Python 3.11.

Após a leitura, os dados foram serializados em estruturas intermediárias organizadas em volta das categorias principais do problema: aeronaves, rotas e aeródromos. Essa serialização permitiu uma visualização mais clara dos dados que estavam sendo manipulados nos componentes do modelo matemático.

O cálculo do CASK, discutido com mais detalhes na Seção 5.3, foi realizado através de uma função implementada utilizando a biblioteca *NumPy* (versão 1.26.0), aplicando a equação proposta por Pereira (2021). Os coeficientes empregados foram os mesmos obtidos pelo autor a partir da regressão linear com dados reais, e a aplicação da equação considera os valores de capacidade de passageiros da aeronave e distância da rota.

6.2 Saída do método

Após a resolução do modelo, a aplicação gera automaticamente um arquivo no formato .csv contendo o resultado das alocações definidas pelo método de otimização. Esse arquivo descreve, para cada combinação de destino e tipo de aeronave, os valores calculados de fluxo (número de voos), passageiros transportados e indicadores binários que demonstram as decisões do modelo.

No arquivo gerado, cada linha representa a alocação de uma aeronave a um determinado destino. As colunas indicam o nome do destino atendido, o modelo da aeronave utilizada, a quantidade de voos semanais realizados naquela rota, e o número total de passageiros transportados no mesmo período. Além dessas informações, o arquivo também apresenta duas variáveis de decisão: uma que indica se a rota está ativa (ou seja, se recebeu alocação), e a outra que indica se a aeronave foi utilizada em pelo menos uma rota. Um exemplo de planilha gerada pela aplicação pode ser visualizado na Seção 6.2.

Destination	Airplane	Flow	Passengers	Active Route	Active Airplane
SBAR	embraer_e175_e2	10	160	Yes	Yes
SBBR	boeing_737_max_7	10	1250	Yes	Yes
SBCF	embraer_e190_e2	10	890	Yes	Yes
SBCG	cessna_408_skycourier	10	190	Yes	Yes
SBCG	pilatus_pc_12_ngx	10	20	Yes	Yes
SBFL	airbus_a320neo	20	3540	Yes	Yes
SBGL	airbus_a220_100	10	1060	Yes	Yes
SBGO	atr_72_600	10	520	Yes	Yes
SBKP	boeing_737_max_8	20	3130	Yes	Yes
SBRJ	atr_42_600	10	430	Yes	Yes
SBSP	airbus_a319neo	10	1500	Yes	Yes
SBVT	cessna_208b_grand_caravan_ex	10	90	Yes	Yes
Valor objetivo	1805898.7526388967				

Figura 6.1 – Exemplo resumido de planilha de alocações de aeronaves

A geração da planilha é feita com o uso da biblioteca *pandas* (versão 2.2.0), a partir da estrutura de dados final do modelo resolvido. O formato adotado tem como objetivo permitir o pós-processamento dos resultados, bem como facilitar a visualização dos dados por meio da construção de tabelas de análise.

6.3 Implementação

6.3.1 Resolvedor matemático e ferramentas utilizadas

A implementação da aplicação foi realizada na linguagem de programação Python (versão 3.11), escolhida pela sua facilidade de programação. Para a resolução do modelo matemático, foi utilizada a biblioteca *gurobipy* (versão 12.0.1), a qual fornece a interface em Python para o resolvedor Gurobi (versão 12.0.1). A escolha do Gurobi se deu pela facilidade na obtenção de licenças acadêmicas gratuitas, bem como pelo domínio técnico do professor orientador sobre a ferramenta, o que facilitou sua integração ao projeto.

Além do Gurobi, outras bibliotecas foram utilizadas no projeto, como as já mencionadas anteriormente *pandas* e *json*, bem como *openpyxl* (versão 3.1.5) para leitura e escrita em arquivos *.xlsx*, e *math* para operações matemáticas básicas.

6.3.2 Funcionamento da aplicação

A aplicação foi projetada para executar todas as etapas do processo de alocação de forma automatizada. Inicialmente, os dados de entrada – referentes a aeronaves, aeródromos, demanda de passageiros e tarifas médias – são lidos de arquivos nos formatos *.xlsx* e *.json* de uma pasta pré-definida na organização interna do projeto chamada *input*.

Após a leitura, os dados são serializados por meio de classes que representem abstrações dos elementos do problema, tais como *Airplane*, *Airport* e *Route*. Essas classes foram projetadas para armazenar, validar e encapsular os dados de forma orientada a objetos. Cada classe possui atributos diretamente relacionados aos dados obtidos dos arquivos de entrada, permitindo assim um acesso estruturado e seguro das informações ao longo da execução da aplicação.

A etapa seguinte consiste na definição das variáveis de decisão, as quais representam as decisões que o modelo (descrito na Seção 5.4) poderá tomar, como alocar ou não uma aeronave, ou quantos voos semanais atribuir a uma determinada rota. Na Figura 6.2 é apresentado um exemplo da implementação da atribuição da variável de decisão que indica se uma aeronave será alocada a um determinado destino.

```

1      key = (route.destination, airplane.id())
2      BIN[key] = model.addVar(vtype=GRB.BINARY, name=f"BIN_{key}")

```

Figura 6.2 – Exemplo de implementação da atribuição da variável de decisão $BIN_{i,a}$

Após definir as variáveis, são adicionadas as restrições do modelo, que garantem que as soluções geradas respeitem as condições técnicas e operacionais do problema. Isso inclui limites de capacidade, exigências de pista, restrições de demanda, entre outras. Na Figura 6.3 é apresentada a implementação da restrição que garante a compatibilidade entre a superfície da pista e a superfície mínima para a aeronave.

```

1      key = (route.destination, airplane.id())
2      model.addConstr(larger_runway_surface >= airplane.min_runway_surface *
        ↪ variables.BIN[key], name=f"runway_surface_{key}")

```

Figura 6.3 – Exemplo de implementação da restrição de compatibilidade de superfície mínima da pista

Por fim, é definida a função objetivo, que busca uma maximização do lucro da companhia aérea, a qual pode ser visualizada na Figura 6.4. Esta função é calculada como a diferença entre a receita obtida com o transporte de passageiros e os custos operacionais, estimados com base no CASK. A implementação utiliza a função *quicksum* do *gurobipy*, que permite somar termos relacionados às variáveis e seus respectivos coeficientes.

```

1      model.setObjective(gp.quicksum(
2          (variables.T[(route.destination, airplane.id())] *
        ↪ variables.P[(route.destination, airplane.id())]) -
3          (variables.C[(route.destination, airplane.id())] * airplane.seats *
        ↪ variables.D[route.origin, route.destination] *
        ↪ variables.F[(route.destination, airplane.id())])
4          for route in routes for airplane in airplanes
5      ), GRB.MAXIMIZE)

```

Figura 6.4 – Exemplo de implementação da função objetivo de maximização do lucro operacional

7. RESULTADOS

Este capítulo apresenta os resultados obtidos a partir da aplicação do modelo matemático para a definição da malha aérea e seleção das aeronaves para uma nova companhia aérea regional com *hub* em Chapecó. Inicialmente, são descritas as fontes dos dados utilizados e o ambiente computacional empregado nas simulações. Em seguida, são apresentados e analisados os resultados obtidos em diferentes cenários operacionais, definidos com base na quantidade máxima de tipos de aeronaves que são utilizadas na operação.

7.1 Fontes de dados e ambiente computacional

Para a realização das simulações deste trabalho, foram utilizados dados públicos disponibilizados por órgãos oficiais. Os dados de demanda e tarifa média foram obtidos por meio do portal DataSAS (ANAC, 2025a), considerando os anos de 2019 e 2024. A escolha desses dois períodos teve como objetivo permitir uma análise comparativa de possíveis alterações no mercado aéreo regional, como mudanças de demanda e preço das passagens ao longo desse período. Adicionalmente, os dados sobre aeródromos públicos foram obtidos por meio da página de dados abertos da ANAC (ANAC, 2025b), enquanto os dados necessários para o cálculo do custo por assento-quilômetro (CASK) foram extraídos da “Matriz Origem Destino” da plataforma Hórus (SAC, 2024).

Durante o processo de preparação dos dados, foram considerados exclusivamente os registros de voos realizados cuja origem corresponde ao aeroporto de Chapecó, compatível com proposta do presente estudo. Como os dados do DataSAS são disponibilizados em arquivos mensais, foi necessário realizar o agrupamento dessas informações. Todos os registros com origem em Chapecó foram reunidos em uma única planilha, e em seguida, realizou-se um somatório do número de assentos por destino, e o cálculo da média das tarifas correspondentes. Esse pré-processamento resultou em uma base anualizada, representando, para cada destino, o volume total de assentos vendidos e a tarifa média no respectivo ano, garantindo maior fidelidade na comparação entre os cenários simulados para 2019 e 2024. A partir dessa base anual, foi possível estimar a média semanal de assentos por destino, dividindo-se o total anual por 52 (número de semanas do ano).

A seleção dos anos de 2019 e 2024 para a realização das simulações se justifica em critérios técnicos relevantes. O ano de 2019 foi escolhido por represen-

tar o último período completo antes dos impactos da pandemia do vírus SARS-CoV-2 (COVID-19) sobre o setor aéreo, caracterizando-se como uma referência de estabilidade operacional e de comportamento regular da demanda. Além disso, trata-se de um ano para o qual estão disponíveis dados que viabilizam o cálculo de custos operacionais de voo, em especial o CASK, indicador essencial para o modelo proposto. Já o ano de 2024 foi selecionado por oferecer os dados disponíveis mais atualizados no momento da realização deste estudo, permitindo avaliar as possíveis transformações ocorridas no mercado aéreo regional brasileiro após o período pandêmico. Todavia, devido à inexistência das informações necessárias para a estimativa do CASK em 2024, optou-se por utilizar os mesmos parâmetros calculados para o ano de 2019, conforme descrito na Seção 5.3.

As simulações foram realizadas em um ambiente computacional com as seguintes especificações técnicas:

Tabela 7.1 – Especificações de *hardware* da máquina de simulação

Componente	Especificação
Processador	Intel® Core™ i5-1240P @ 1.70 GHz
Memória RAM	16 GB LPDDR5 4800 MHz
Sistema Operacional	Windows 11.24H2 (64 bits)

7.2 Malha aérea

A definição das malhas aéreas utilizadas nas simulações foram realizadas com base nos critérios descritos anteriormente na Seção 5.1. A partir da aplicação desses critérios nos dados de demanda obtidos, foram selecionados os destinos que compõem a malha aérea de cada um dos anos analisados.

Para o ano de 2019, foram selecionados 34 destinos, cujos códigos dos aeródromos estão apresentados na Tabela 7.2, os quais são definidos pela Organização da Aviação Civil Internacional (ICAO, do inglês *International Civil Aviation Organization*). A distribuição geográfica desses destinos pode ser visualizada na Figura 7.1, que ilustra a malha aérea resultante para este ano.

Tabela 7.2 – Destinos selecionados para o ano de 2019

Destinos selecionados para o ano de 2019							
SBAR	SBBE	SBBR	SBCF	SBCG	SBCT	SBCY	SBEG
SBFL	SBFZ	SBGL	SBGO	SBGR	SBJP	SBKP	SBLO
SBMG	SBMO	SBPA	SBPJ	SBPS	SBPV	SBRF	SBRJ
SBRP	SBSG	SBSL	SBSO	SBSR	SBSV	SBTE	SBUL
SBVT	SBZM						




Figura 7.1 – Malha aérea resultante para o ano de 2019

Já para o ano de 2024, a aplicação dos mesmos critérios resultou em uma malha aérea composta por 35 destinos, listados na Tabela 7.3 através de seus respectivos códigos ICAO. A distribuição geográfica equivalente dos destinos selecionados está apresentada na Figura 7.2.

Tabela 7.3 – Destinos selecionados para o ano de 2024

Destinos selecionados para o ano de 2024							
SBAR	SBBE	SBBR	SBBV	SBCF	SBCG	SBCT	SBCY
SBEG	SBFL	SBFZ	SBGL	SBGO	SBGR	SBIL	SBJP
SBKP	SBMO	SBPA	SBPJ	SBPS	SBPV	SBRF	SBRJ
SBRP	SBSG	SBSI	SBSL	SBSO	SBSP	SBSR	SBSV
SBTE	SBUL	SBVT					




Figura 7.2 – Malha aérea resultante para o ano de 2024

Comparando os dois anos, observou-se que as malhas aéreas foram diferentes, refletindo as mudanças nas condições de mercado e na demanda regional ao longo do período. Como exemplo dessas diferenças destaca-se a inclusão do destino SBBV (Boa Vista, RR) na malha de 2024, enquanto o destino SBLO (Londrina, PR), presente em 2019, deixou de ser considerado na malha aérea mais recente.

7.3 Cenários

Nesta seção, serão apresentados os resultados obtidos com a aplicação do modelo matemático em seis diferentes cenários operacionais. Cada cenário foi definido pela quantidade máxima de tipos distintos de aeronaves que estarão disponíveis para atender a malha aérea. Os cenários analisados são:

1. Apenas um tipo de aeronave;
2. Até dois tipos de aeronave;
3. Até três tipos de aeronave;
4. Até cinco tipos de aeronave;

5. Até dez tipos de aeronave;
6. Sem limite de tipos de aeronave.

Análises estruturadas com base em diferentes níveis de flexibilidade na composição da frota já foram adotadas em trabalhos anteriores, como os de Jesus (2019) e Pereira (2021), os quais utilizaram abordagens semelhantes para avaliar o impacto da diversificação da frota sobre a viabilidade e eficiência da operação aérea regional. Inspirando-se nessas contribuições, este estudo adotou uma estratégia parecida, permitindo a comparação de resultados sob diferentes configurações de frota e contextos temporais.

7.3.1 Primeiro cenário

No primeiro cenário, foi considerada a utilização de apenas um tipo de aeronave para atender todas as rotas da malha aérea proposta. Essa limitação teve como objetivo avaliar a viabilidade operacional de uma frota homogênea, característica esta que pode trazer muitas vantagens operacionais para a companhia aérea, como a facilidade na manutenção. Porém, uma frota composta por aeronaves do mesmo modelo pode prejudicar a capacidade de atendimento a todas as rotas, especialmente considerando as diferenças de demanda e infraestrutura dos aeródromos.

Os resultados obtidos para os anos de 2019 e 2024 estão apresentados na Tabela 7.4.

Tabela 7.4 – Resultado da alocação com apenas um tipo de aeronave

Apenas um tipo de aeronave		
	2019	2024
Resultado	Inviável	Inviável
Lucro (R\$)	–	–

Como mostrado na Tabela 7.4, o cenário com apenas um tipo de aeronave mostrou-se inviável tanto em 2019 quanto em 2024. A utilização de apenas um modelo para operar toda a malha não produziu uma solução viável, e isso se deve principalmente às restrições operacionais impostas no modelo.

Analisando o arquivo gerado pelo resolvedor Gurobi, é possível notar que a inviabilidade está relacionada ao fato de que nenhuma aeronave atende simultaneamente todos os destinos, respeitando os critérios impostos. Entre os principais fatores identificados estão:

- Restrições de comprimento de pista, as quais impedem o uso de aeronaves maiores em aeródromos com menos infraestrutura;
- Restrições de autonomia, que inviabilizam a utilização de aeronaves menores em rotas longas;
- Exigência de atender à demanda mínima por destino, juntamente com a limitação de capacidade das aeronaves.

Por exemplo, na restrição de autonomia, o modelo descartou a utilização do ATR 72-600 em rotas longas, como a que liga Chapecó ao aeródromo de SBPV (Porto Velho, RO), devido à exigência de autonomia mínima de cerca de 2.365 quilômetros – superior à autonomia operacional da aeronave, que é de aproximadamente 1.370 quilômetros, quando em seu peso máximo de decolagem. Já em relação às restrições de comprimento de pista, o modelo descartou o uso do Airbus A319neo em aeródromos como o SBRJ (Rio de Janeiro, RJ), onde o comprimento da pista disponível é de cerca de 1.323 metros, enquanto a aeronave requer 1.800 metros.

Dessa forma, o modelo não foi capaz de alocar um único modelo de aeronave que satisfizesse todas as exigências técnicas e comerciais da malha aérea proposta. Esse resultado confirma a necessidade de diversificação mínima na frota, como também foi observado por Jesus (2019).

7.3.2 Segundo cenário

No segundo cenário, foi permitido que o modelo selecionasse até dois tipos distintos de aeronaves para atender a malha aérea. Esse acréscimo de diversidade operacional permitiu ao modelo explorar uma combinação de aeronaves com características complementares, buscando maior eficiência no atendimento das rotas.

A Tabela 7.5 apresenta os resultados obtidos pelo modelo ao operar a malha com até dois tipos de aeronaves.

Tabela 7.5 – Resultado da alocação com até dois tipos de aeronave

Até dois tipos de aeronave				
2019			2024	
Resultado	Aeronave	Rotas	Aeronave	Rotas
	C408	18	A220-100	26
	E175-E2	22	C208B EX	12
Lucro (R\$)	1.290.937,39		1.735.114,56	

A alocação de até dois tipos de aeronave mostrou-se viável para ambos os anos, com um lucro operacional de R\$ 1.290.937,39 em 2019 e R\$ 1.786.471,76 em 2024. A diferença representa um aumento de aproximadamente 34,4% na lucratividade entre os anos. No entanto, ao analisar os dados agregados de demanda e tarifas, observa-se que esse resultado não está relacionado ao crescimento da demanda – que, na verdade, apresentou uma redução de cerca de 6,8% –, mas sim ao aumento significativo da tarifa média, que passou de R\$ 770,77 em 2019 para R\$ 1.276,83 em 2024, um aumento de cerca de 65,6%.

Em termos de composição da frota, houveram diferenças significativas entre os dois anos. Em 2019, o modelo selecionou as aeronaves Cessna 408 SkyCourier (45% das rotas) e o Embraer E175-E2 (55% das rotas), enquanto em 2024 o modelo optou pelo Airbus A220-100 (68,4% das rotas) e o Cessna 208B Grand Caravan EX (31,6% das rotas). Nota-se que, em ambos os anos, o modelo selecionou uma combinação entre uma aeronave de maior alcance e capacidade e uma aeronave de menor porte, voltada a rotas de baixa demanda ou pistas curtas.

7.3.3 Terceiro cenário

Neste cenário, o modelo teve a liberdade de utilizar até três tipos distintos de aeronaves para compor a frota. Essa configuração acentuou ainda mais a capacidade de adaptação às características operacionais específicas de cada rota. Os dados da alocação de até três tipos de aeronaves estão organizados na Tabela 7.6, com os respectivos resultados para 2019 e 2024.

Tabela 7.6 – Resultado da alocação com até três tipos de aeronave

Até três tipos de aeronave				
2019			2024	
	Aeronave	Rotas	Aeronave	Rotas
Resultado	A320neo	3	A220-100	7
	C408	16	C208B EX	13
	E175-E2	20	E175-E2	20
Lucro (R\$)	1.311.949,52		1.786.471,76	

A lucratividade neste cenário aumentou de R\$ 1.311.949,52 em 2019 para R\$ 1.795.988,43 em 2024, um acréscimo de 36,9%. Tal como no cenário anterior, o ganho é atribuído principalmente à elevação das tarifas médias, uma vez que a demanda apresentou um decréscimo no ano mais recente dos dois analisados.

Desta vez, o modelo combinou aeronaves com perfis distintos: jatos regionais (Embraer E175-E2 e Airbus A220-100) e aeronaves utilitárias leves (Cessna 208B Grand Caravan EX e Cessna 408 SkyCourier). A permanência do Embraer E175-E2 em ambos os anos reforça sua versatilidade para rotas regionais de média densidade, enquanto as demais aeronaves complementam o atendimento a destinos com limitações operacionais.

7.3.4 Quarto cenário

Com até cinco tipos de aeronaves, o cenário quatro apresentou ainda maior diversificação operacional, como pode ser visto na Tabela 7.7. Esse cenário foi economicamente vantajoso, quando comparado com o cenário anterior, refletindo novamente a vantagem da diversificação da frota.

Tabela 7.7 – Resultado da alocação com até cinco tipos de aeronave

Até cinco tipos de aeronave				
2019			2024	
Resultado	Aeronave	Rotas	Aeronave	Rotas
	A320neo	3	A220-100	4
	ATR 42-600	5	A320neo	3
	C208B EX	8	C208B EX	10
	C408	9	C408	6
	E175-E2	18	E175-E2	19
Lucro (R\$)		1.322.608,81	1.795.988,43	

Em comparação com o cenário anterior, o lucro cresceu para R\$ 1.322.608,81 (0,8%) em 2019 e R\$ 1.795.988,43 (0,5%) em 2024, mantendo uma tendência de melhoria gradual. A permanência de modelos como o Embraer E175-E2 em ambos os anos destaca sua eficiência recorrente nas simulações, enquanto as demais aeronaves foram ajustadas conforme a necessidade.

A composição da frota incluiu jatos (e.g., A320neo), turboélices regionais (e.g., ATR 42-600) e aeronaves utilitárias leves (e.g., C208B EX), permitindo um atendimento versátil. Além disso, é possível observar que o modelo distribuiu adequadamente as aeronaves entre as rotas mais densas (com maior demanda), como o destino SBGR, e destinos com limitações de infraestrutura, como SBRJ, e/ou baixa demanda, maximizando o uso dos recursos disponíveis.

7.3.5 Quinto cenário

Esse cenário permitiu ao modelo utilizar uma ampla variedade operacional, podendo escolher até dez tipos distintos de aeronaves. Os resultados da alocação podem ser visualizados na Tabela 7.8.

Tabela 7.8 – Resultado da alocação com até dez tipos de aeronave

Até dez tipos de aeronave				
2019		2024		
Resultado	Aeronave	Rotas	Aeronave	Rotas
	A220-300	1	A220-100	2
	A320neo	3	A319neo	3
	ATR 42-600	3	A320neo	3
	ATR 72-600	3	ATR 42-600	1
	B737 MAX 8	1	ATR 72-600	1
	C208B EX	1	B737 MAX 7	1
	C408	7	C208B EX	7
	E175-E2	14	C408	5
	E190-E2	3	E175-E2	15
	PC-12 NGX	4	E190-E2	3
Lucro (R\$)		1.328.596,91	1.805.568,89	

O lucro neste cenário, quando comparado com o cenário anterior, atingiu R\$ 1.328.596,91 (0,4%) em 2019, e R\$ 1.805.568,89 (0,5%) em 2024, o maior lucro entre os cenários com restrição de tipos de aeronaves. A ampliação da diversidade da frota permitiu ao modelo aproveitar melhor as características individuais das aeronaves, otimizando o atendimento em função das restrições de cada rota.

Em termos de perfil operacional, os jatos regionais concentraram a maior parte das rotas em ambos os anos, sendo 45% em 2019 e 49% em 2024. As aeronaves utilitárias leves atenderam a 30% das rotas em 2019 e 29% em 2024. Os turboélices regionais corresponderam a 15% das rotas em 2019, mas apenas 5% em 2024. Por fim, os jatos *narrowbody* tradicionais corresponderam a 10% em 2019 e 17% em 2024.

Também, observa-se que foram incluídas aeronaves como Airbus A319neo, Embraer E190-E2 e Boeing B737 MAX 7, aeronaves que ainda não haviam sido utilizadas, destacando o uso de jatos maiores para rotas mais densas. Mesmo assim, modelos como o Embraer E175-E2 e Cessna 408 SkyCourier permaneceram relevantes, indicando que a estratégia do modelo se apoia em uma base de aeronaves versáteis, complementadas por opções pontuais conforme a demanda.

7.3.6 Sexto cenário

No último cenário analisado, não houve restrição quanto ao número de tipos de aeronaves que o modelo poderia utilizar, com o objetivo de visualizar como o modelo se comportaria. A Tabela 7.9 resume os resultados do cenário, permitindo uma análise do comportamento ótimo do modelo.

Tabela 7.9 – Resultado da alocação sem limite de tipos de aeronave

Sem limite de tipos de aeronave				
2019		2024		
	Aeronave	Rotas	Aeronave	Rotas
Resultado	A220-300	1	A220-100	2
	A320neo	3	A319neo	1
	ATR 42-600	3	A320neo	2
	ATR 72-600	3	ATR 42-600	1
	B737 MAX 8	1	ATR 72-600	1
	C208B EX	1	B737 MAX 7	1
	C408	7	B737 MAX 8	2
	E175-E2	14	C208B EX	2
	E190-E2	3	C408	5
	PC-12 NGX	4	E175-E2	15
	—	—	E190-E2	3
	—	—	PC-12 NGX	5
Lucro (R\$)		1.328.596,91	1.805.898,75	

No ano de 2024, o lucro foi o mais elevado de todos os cenários, atingindo R\$ 1.805.898,75. Entretanto, o ganho adicional em relação ao cenário anterior com até dez tipos não foi tão relevante, sendo de apenas 0,02%, sugerindo que o modelo já havia se aproximado de uma solução quase ótima com dez tipos diferentes. Já para o ano de 2019, nada mudou quanto ao lucro, apenas mudanças nas aeronaves selecionadas.

Foram utilizadas doze aeronaves diferentes, no ano com maior diversidade, variando de modelos de pequeno porte, como o Pilatus PC-12 NGX, até jatos comerciais, como o Boeing B737 MAX 8. Novamente, os jatos regionais atenderam à maior parte das rotas, com 45% em 2019 e 50% em 2024. As aeronaves utilitárias leves representaram 30% das rotas em ambos os anos. Já os turboélices regionais tiveram uma redução na participação, passando de 15% em 2019 para 5% em 2024. Por fim, os jatos *narrowbody* tradicionais corresponderam a 10% das rotas em 2019 e 15% em 2024.

7.4 Análise dos resultados

Ao analisar os diferentes cenários simulados, é possível identificar alguns padrões consistentes entre os anos de 2019 e 2024. Um ponto de destaque é que, em todos os cenários viáveis, o modelo selecionou pelo menos uma aeronave utilitária leve e um jato regional, demonstrando uma estratégia de diversificação onde uma aeronave complementa a outra, similar ao que vemos em companhias aéreas reais. Por exemplo, o modelo optou por manter determinadas aeronaves nas soluções dos dois anos, como o Embraer E175-E2 e o Cessna 208B Grand Caravan EX, sendo uma aeronave utilizada em rotas mais distantes e/ou com maior demanda, e a outra utilizada em cenários com infraestrutura mais limitada.

Outro aspecto comum é que o lucro operacional obtido em 2024 foi sistematicamente superior ao de 2019 em todos os cenários viáveis. Essa diferença, como já explicada anteriormente, não foi causada pelo aumento na demanda agregada, a qual na realidade recuou cerca de 6,8%, mas sim por conta de um acréscimo significativo nas tarifas médias, que cresceram aproximadamente 65,6% entre os dois anos. Esse crescimento compensou a menor movimentação de passageiros e resultou em uma maior rentabilidade.

Na comparação entre os diferentes cenários, observa-se que o aumento da diversidade na frota não resultou em acréscimos substanciais no lucro. A maior diferença percentual de lucro entre os extremos – cenário com dois tipos de aeronaves e o cenário sem limite – foi de apenas 4,1%. Isso indica que, uma vez atingido um nível mínimo de flexibilidade operacional, o modelo já é capaz de alcançar uma solução economicamente eficiente. A incorporação de novos tipos de aeronaves após esse ponto contribui pouco para o desempenho financeiro, e a operação pode se tornar mais complexa.

Considerando os resultados obtidos, o cenário com cinco tipos de aeronaves destacou-se como uma solução particularmente eficiente, combinando alta lucratividade com uma composição de frota ainda gerenciável. De forma semelhante ao que foi observado por Jesus (2019), a diversificação da frota possibilitou o atendimento eficaz de uma malha aérea com diferentes perfis de demanda e infraestrutura, porém, os ganhos estabilizaram após um determinado nível de flexibilidade. Deste modo, apesar do sexto cenário ter obtido o melhor lucro absoluto, o quarto cenário pode ser considerado o mais vantajoso do ponto de vista operacional, já que apresentou desempenho próximo ao ótimo com uma menor complexidade de implementação.

8. CONCLUSÃO

A presente pesquisa teve como objetivo selecionar, adaptar e implementar um modelo de programação linear inteira capaz de resolver o problema de definição da malha aérea e da seleção das aeronaves para uma nova companhia aérea regional com *hub* em Chapecó. O modelo desenvolvido buscou a maximização da lucratividade e a eficiência operacional da empresa, simultaneamente respeitando restrições operacionais e econômicas específicas do setor da aviação regional brasileira.

Primeiramente, foram explorados conceitos essenciais relacionados ao planejamento de malhas aéreas e à seleção de frotas, proporcionando uma base teórica sólida para as etapas seguintes. A partir dessa fundamentação, foi realizada uma análise detalhada de modelos matemáticos já existentes, resultando na escolha do modelo proposto por Jesus (2019), o qual foi aplicado a um cenário muito similar ao estudado neste trabalho.

A resolução do modelo exigiu a adaptação de algumas das etapas metodológicas. Realizou-se o tratamento dos dados de entrada obtidos através de plataformas públicas, abrangendo informações sobre demanda de passageiros, tarifas médias, características das aeronaves e infraestrutura aeroportuária. Foi também implementado o cálculo do CASK com base no método de regressão linear previamente publicado no trabalho de Pereira (2021), além da inclusão de uma nova restrição relacionada à superfície mínima de pista para cada modelo de aeronave – contribuição adicional deste trabalho.

A execução das simulações em diferentes configurações de diversidade de frota permitiu a análise comparativa dos resultados para os cenários de 2019 e 2024. Foi possível entender que, para a viabilização econômica da operação, a diversificação da frota é extremamente importante. Destacou-se, por exemplo, a inviabilidade de atender completamente a malha aérea com apenas um tipo de aeronave, além da identificação de um ganho moderado no lucro operacional ao ampliar a frota para mais de dois tipos de aeronaves.

Além disso, a análise dos resultados mostrou a predominância na utilização de aeronaves menores na composição final da frota, como jatos regionais e aeronaves utilitárias leves, característica também observada por Jesus (2019) em seu trabalho. Observou-se também que, mesmo com alterações na malha aérea entre 2019 e 2024, a estrutura de alocação de aeronaves manteve características semelhantes em termos de perfil de aeronaves e distribuição das frotas.

Embora avanços foram conseguidos, algumas limitações foram identificadas. Uma delas refere-se à utilização de um único conjunto de parâmetros de CASK (calculado com base nos dados de 2019) para ambos os anos, devido à indisponibilidade de dados mais recentes para a obtenção de resultados mais realistas para o ano de 2024. Outra limitação foi a falta de tempo para tratar as restrições relacionadas à infraestrutura das pistas, optando-se a uma abordagem mais simplificada, considerando apenas o tipo de superfície.

Como trabalhos futuros, destaca-se a possibilidade de incorporar a análise de compatibilidade ACN/PCN (ACN – número de classificação da aeronave, do inglês *Aircraft Classification Number*; PCN – número de classificação do pavimento, do inglês *Pavement Classification Number*) de forma mais detalhada, enriquecendo o critério de viabilidade operacional dos aeródromos. Além disso, a aplicação do modelo em diferentes localidades, com cenários de *hub* alternativos, pode oferecer novos horizontes sobre a configuração ótima de malhas aéreas regionais no Brasil.

Conclui-se que, o modelo matemático implementado atendeu aos objetivos propostos neste trabalho, contribuindo para uma ferramenta robusta de apoio à tomada de decisão no planejamento estratégico de companhias aéreas regionais.

REFERÊNCIAS BIBLIOGRÁFICAS

ANAC. *Aeroportos: Entendendo como funciona o setor aéreo*. 2021. Acesso em: 25 de outubro de 2024. Disponível em: <<https://www.gov.br/anac/pt-br/centrais-de-conteudo/por-dentro-da-aviacao/aeroportos/aeroportos>>.

ANAC. *Agência Nacional de Aviação Civil*. 2024. Acesso em: 22 de outubro de 2024. Disponível em: <<https://www.gov.br/anac/pt-br/acesso-a-informacao/institucional/institucional>>.

ANAC. *Painel de Indicadores do Transporte Aéreo 2023*. 2024. Acesso em: 17 de novembro de 2024. Disponível em: <<https://www.gov.br/anac/pt-br/assuntos/dados-e-estatisticas/mercado-do-transporte-aereo/painel-de-indicadores-do-transporte-aereo/painel-de-indicadores-do-transporte-aereo-2023>>.

ANAC. *DataSAS*. 2025. Acesso em: 21 de maio de 2025. Disponível em: <<https://www.gov.br/anac/pt-br/acesso-a-informacao/dados-abertos/areas-de-atuacao/voos-e-operacoes-aereas/tarifas-aereas-domesticas/tarifas-aereas-recurso-de-filtro>>.

ANAC. *Lista de aeródromos públicos*. 2025. Acesso em: 27 de maio de 2025. Disponível em: <<https://sistemas.anac.gov.br/dadosabertos/Aerodromos/Aer%C3%B3dromos%20P%C3%ABlicos/Lista%20de%20aer%C3%B3dromos%20p%C3%ABlicos/>>.

ARENALES, M. et al. *Pesquisa operacional*. Rio de Janeiro, RJ: Elsevier Brasil, 2006.

AZUL. *Mapa de Rotas*. 2024. Acesso em: 25 de novembro de 2024. Disponível em: <<https://www.voeazul.com.br/pt/sobreazul/mapa-de-rotas>>.

BAZARGAN, M. *Airline Operations and Scheduling*. New York: Ashgate, 2010.

BETTINI, H. Um Retrato da Aviação Regional no Brasil. *Revista de Literatura dos Transportes*, v. 1, n. 1, 2007.

CHOI, J.; LEE, C.; PARK, S. Dantzig–wolfe decomposition approach to the vehicle assignment problem with demand uncertainty in a hybrid hub-and-spoke network. *Annals of Operations Research*, v. 264, 2018.

CORTEZ, D. A.; COLUCCI, L. R.; Sá, R. L. C. d. *Otimização de Viagens em Companhias Aéreas Brasileiras*. Tese (Trabalho de Graduação) — Universidade de São Paulo, São Paulo, SP, 2012.

EMBRAER. *E195-E2 Embraer Commercial Jet*. 2024. Acesso em: 25 de outubro de 2024. Disponível em: <<https://www.embraercommercialaviation.com/commercial-jets/e195-e2-commercial-jet/>>.

FELIPE, J. R. *Modelagem do Problema da Alocação de Frota Aplicado à Aviação Regional A Partir da Redução da Complexidade Computacional*. Tese (Trabalho de Graduação) — Universidade de Brasília, Brasília, DF, 2022.

GILLEN, D. Aviation economics and forecasting. In: *Air Transport Management*. 2. ed. Londres: Routledge, 2020. p. 19.

GUROBI. *Gurobi Optimizer Reference Manual*. 2025. Acesso em: 25 de outubro de 2024. Disponível em: <<https://www.gurobi.com>>.

JESUS, T. d. *Definição da malha aérea e aeronaves para uma nova companhia aérea regional com hub em Goiânia*. Tese (Trabalho de Graduação) — Universidade de Brasília, Brasília, DF, 2019.

LINDO. *LINGO*. 2024. Acesso em: 16 de outubro de 2024. Disponível em: <<https://www.lindo.com/>>.

MEDAU, J. C. *Alocação de aeronaves a voos considerando restrições operacionais, de manutenção e de desempenho das aeronaves*. Tese (Doutorado) — Universidade de São Paulo, São Paulo, SP, 2017.

MOTTA, L. et al. *Otimização de inspeções de manutenção de aeronaves através do uso de tecnologia*. Tese (Especialização) — Fundação Dom Cabral, Recife, PE, 2020.

MPOR, M. d. P. e. A. *Aviação regional brasileira será impulsionada com inclusão de 13 novas aeronaves*. 2024. Acesso em: 25 de outubro de 2024. Disponível em: <<https://www.gov.br/portos-e-aeroportos/pt-br/assuntos/noticias/2024/04/aviacao-regional-brasileira-sera-impulsionada-com-inclusao-de-13-novas-aeronaves>>.

NEMHAUSER, G. L.; WOLSEY, L. A. *Integer and Combinatorial Optimization*. Hoboken, NJ: John Wiley & Sons, 1999.

NYGREN, E.; ALEKLETT, K.; Höök, M. Aviation fuel and future oil production scenarios. *Energy Policy*, v. 37, n. 10, p. 4003–4010, 2009.

PEREIRA, G. H. d. S. *Estudo de metodologia de otimização para o problema de alocação de frota na aviação regional*. Tese (Trabalho de Graduação) — Universidade de Brasília, Brasília, DF, 2021.

PEROVIC, J. The economic benefits of aviation and performance in the travel & tourism competitiveness index. *The Travel & Tourism Competitiveness Report 2013*, v. 1, n. 1, 2013.

SAC, S. N. d. A. C. *Hórus*. 2024. Acesso em: 16 de outubro de 2024. Disponível em: <<https://horus.labtrans.ufsc.br/>>.

SANTOS, P. V. S.; SILVA, E. C. da. Panorama da aviação civil no brasil: uma análise. *Brazilian Journal of Production Engineering*, v. 5, n. 1, p. 122–142, 2019.

SWAN, W. M.; ADLER, N. Aircraft trip cost parameters: A function of stage length and seat capacity. *Transportation Research Part E: Logistics and Transportation Review*, v. 42, n. 2, p. 105–115, 2006.